스코어 기반 생성모델 설명Work

ChatGPT · 2 messages · exported 2026년 11월 6일

You

...

ChatGPT

이 논문을 관통하는 질문은 **"데이터에 잡음을 더하는 과정은 아는데, 그 과정을 거꾸로 돌리려면 왜 로그밀도의 기울기인 스코어를 배워야 할까?"** 야. 저자의 아이디어는 이 질문을 아주 작은 격자 위에서 풀어보는 거야. 가장 직관적인 대목은 역방향 한 걸음을 베이즈 규칙으로 계산하는 부분이야.

1. 공정한 동전도 거꾸로 보면 한쪽으로 기울어져

입자가 매번 공정한 동전을 던져 왼쪽이나 오른쪽으로 만큼 움직인다고 해보자. 지금 입자 하나가 에 도착했어. **이 입자는 왼쪽에서 왔을까, 오른쪽에서 왔을까?**

순방향 이동 확률은 양쪽 다 이지만, 왼쪽에 입자가 90개, 오른쪽에 10개 있었다면 에 도착한 입자의 출발지는 왼쪽일 확률이 90%야. 두 출발지에서 로 올 확률은 같으니, 원래 입자가 많았던 쪽에서 더 많이 도착하는 거지.

이를 식으로 쓰면, 이전 시점의 격자 질량을 라고 할 때 **도착점에서 이전 위치로 되짚어 가는 평균 변위**는 정확히 다음과 같아.

이제 이웃한 격자값이 양의 매끄러운 밀도를 잘 나타낸다고 해보자. 분자의 차이는 대략 이고 분모는 대략 야. 브라운 운동의 스케일인 를 넣으면

여기서 **왜 하필 로그인가**도 풀려. 왼쪽과 오른쪽에서 들어온 입자 수의 *차이*가 분자에 들어가고, 에 도착했다는 조건을 걸면서 *전체 유입량*으로 나누기 때문이야. 그 비율이 연속적인 표현으로 바뀌면 , 즉 스코어가 돼. 스코어가 알려주는 건 한 입자의 과거 위치가 아니라, 같은 위치에 도착한 입자들을 거꾸로 한 걸음 보냈을 때의 **평균 방향**이야. 개별 입자의 움직임에는 여전히 잡음이 남아.

2. '초유한'은 이 계산에서 어떤 역할을 할까?

보통은 유한한 격자에서 시작해서 시간 간격을 계속 줄이는 극한을 생각해. 이 논문은 비표준해석을 써서 처음부터 을 모든 표준 자연수보다 큰 **초자연수**로 두고, 시간 간격을 으로 잡아. 는 양수지만 어떤 양의 실수보다도 작아. 그럼에도 격자 안에서는 번의 이동을 합산하거나 한 단계의 조건부확률을 계산하는 유한 합의 규칙을 그대로 쓸 수 있어.

그다음 유한한 크기의 초실수에서 무한소 차이를 제거해 대응하는 실수를 얻는 연산이 **표준부분** 야. 한 걸음의 잡음은 크기라 표준부분이 0이지만, 독립인 걸음을 번 모으면 누적 분산은 이야. 그래서 **한 걸음씩 표준부분을 취하는 것과, 전부 더한 뒤 표준부분을 취하는 것은 달라**. 후자의 경로에서 브라운 운동이 나타나. 부록이 긴 이유도 이런 경로와 확률을 통상적인 확률론으로 옮기는 조건을 설명하기 때문이야.

본문은 같은 격자를 두 방향에서 봐. 순방향에서는 한 걸음이 시험함수의 평균을 얼마나 바꾸는지 계산해서 밀도의 시간 변화를 기술하는 **포커–플랑크 방정식**을 얻어. 역방향에서는 아까처럼 도착점을 고정하고 출발지를 추론해. 순방향 드리프트가 , 잡음의 공분산 행렬이 이면, 역방향 시계 로 본 평균 속도는 다음 형태야.

첫 항은 원래의 평균 이동을 뒤집고, 둘째 항은 어느 쪽에서 입자가 더 많이 들어왔는지를 반영해. 마지막 항은 잡음의 세기나 방향이 위치에 따라 달라질 때 생겨. 공간적으로 일정한 잡음이면 마지막 항은 사라져. 앞의 동전 예시는 인 경우야.

3. 실제 학습에서는 모르는 스코어를 어떻게 배우지?

생성할 때 필요한 건 잡음이 섞인 **전체 데이터 분포**의 스코어 야. 그런데 학습할 때는 원본 을 우리가 직접 뽑고 잡음도 우리가 더해. 그래서 흔히 쓰는 가우시안 잡음 과정에서는 **그 원본 하나에서 출발했을 때의 조건부 스코어**를 계산할 수 있어.

예를 들어 , 이면 학습 표적은

모델은 만 보고 이 표적을 제곱오차로 예측해. 같은 가 서로 다른 원본에서 나올 수 있으므로 최적 예측은 가능한 표적들의 조건부평균이야. 이 예에서는

이 식을 앞의 동전 예시와 나란히 보면 연결이 보여. **역방향에서는 가능한 출발지를 평균내고, 학습에서는 가능한 원본들이 주는 표적을 평균내.** 두 계산에 같은 주변분포의 스코어가 등장하므로, 학습한 값을 역방향 샘플러에 넣을 수 있어. 논문은 격자에서도 조건부평균이 제곱오차의 최적해라는 점은 정확히 성립하고, 적절한 매끄러움 아래 그 값이 주변분포의 로그 차분에 무한소만큼 가까워진다고 설명해.

여기서 원고를 읽을 때 중요한 구분이 하나 있어. 저자의 생성 수렴 정리는 **전체 학습 손실 가 거의 0**이라고 가정해. 그런데 바로 뒤의 손실 분해에 따르면, 완벽한 모델에도 서로 다른 원본이 같은 를 만들면서 생기는 조건부 분산 가 남아. 위 가우시안 예에서도 만 보고 실제 을 알아낼 수 없는 만큼 표적에 오차가 남지. 그래서 일반적인 학습에서 스코어를 잘 배웠는지를 나타내는 양은 **최적 손실을 초과한 부분**이야. 원고에 적힌 거의 0 가정은 이보다 강해.

4. 뒤쪽의 우도와 4차 모멘트는 왜 나올까?

우도 부분은 학습한 스코어가 틀렸을 때 그 오차가 무엇을 뜻하는지 묻고 있어. 같은 끝분포 에서 출발하고 확산행렬이 일정하다는 등의 가정 아래, 저자는 참 역과정과 학습한 역과정의 **전체 경로 분포** 사이의 KL 발산을 시간에 걸쳐 더한 가중 스코어 제곱오차와 연결해. 생성 결과 하나만 관찰하면 거기까지 온 경로 정보는 사라져. 그래서 최종 샘플 분포의 KL 발산은 전체 경로의 KL 발산 이하이고, 스코어 오차를 줄이면 평균 로그우도의 **하한**이 올라가. 둘 사이에 남는 차이가 원고의 *bridge divergence*, 즉 같은 결과에 도달하는 경로들의 조건부 분포 차이야.

4차 모멘트 부분은 다른 질문을 다뤄. 동전 잡음과 가우시안 잡음은 평균과 분산을 맞추면 같은 브라운 운동을 만들어낼 수 있는데, **한 걸음을 더 정밀하게 보면 둘의 차이가 어디에 남을까?** 1차원에서 계수를 고정하고 평균 0, 분산 1, 3차 모멘트 0인 잡음을 쓰면, 한 걸음의 밀도 전개에서 다음 오차항이 나타나.

공정한 동전 잡음 은 이야. 반면 을 확률 , 과 을 각각 확률 로 뽑으면 분산은 여전히 1이고 이 돼. 가우시안과 전혀 다르게 생긴 이 세 점짜리 잡음도 **해당 오차항**을 없애는 거야. 이 결과의 범위는 계수를 고정한 한 걸음이야. 계수가 공간에 따라 변하면 그 도함수에서 생기는 오차도 따로 봐야 해.

마지막으로, **연속 확산의 밀도가 매끄럽다는 사실과 원래 격자에서 로그 차분을 계산할 수 있다는 사실**은 구분해서 읽을 만해. 예를 들어 한 점에서 출발해 매번 만 움직이는 보행은 짝수 번째 걸음에는 짝수 칸에만 있어. 연속 극한에서는 매끄러운 가우시안 밀도가 생겨도, 그 시점의 격자에서는 바로 옆 칸의 확률이 0이라 를 계산할 수 없어. 따라서 원고의 일반적인 격자 스코어 주장을 쓰려면 전이확률의 양성과 이웃 칸 차분의 제어를 별도로 확보해야 해.

처음 읽을 때는 **역방향 평균의 베이즈 공식**과 **학습 표적의 조건부평균 공식**을 먼저 붙잡으면 돼. 하나는 생성에 왜 스코어가 필요한지를, 다른 하나는 원본에 잡음을 더하는 학습만으로 어떻게 그 스코어를 얻는지를 설명해. 이 둘을 같은 격자 위에서 연결하는 게 이 논문의 중심이야.